

台湾大学林轩田机器学习基石课程学习笔记5 -- Training versus Testing

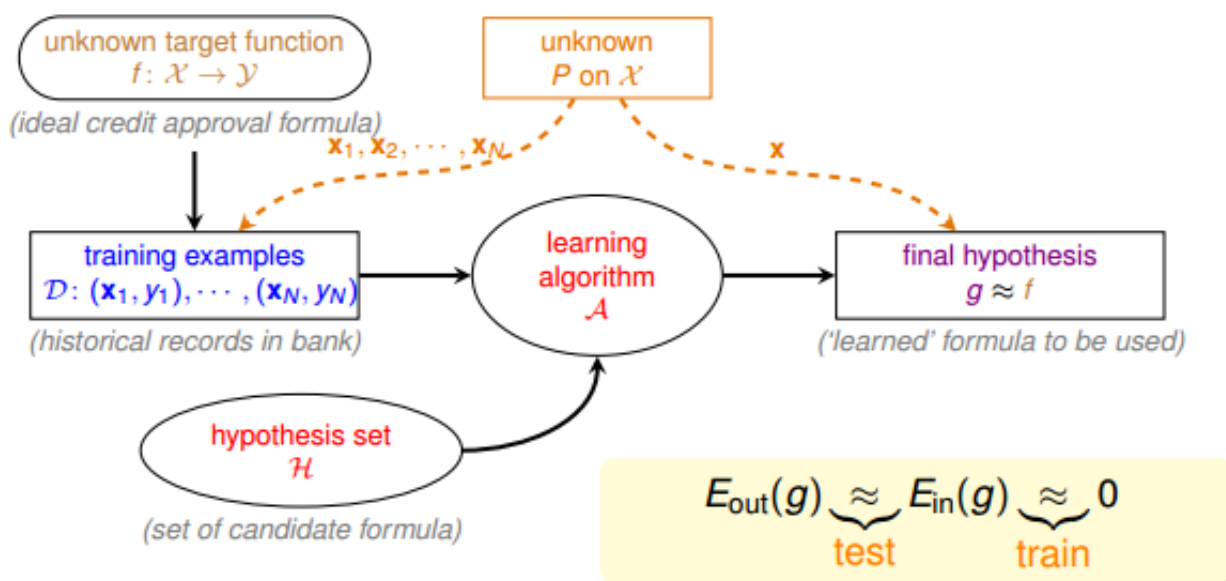
作者：红色石头

微信公众号：AI有道 (ID : redstonewill)

上节课，我们主要介绍了机器学习的可行性。首先，由NFL定理可知，机器学习貌似是不可行的。但是，随后引入了统计学知识，如果样本数据足够大，且hypothesis个数有限，那么机器学习一般就是可行的。本节课将讨论机器学习的核心问题，严格证明为什么机器可以学习。从上节课最后的问题出发，即当hypothesis的个数是无限多的时候，机器学习的可行性是否仍然成立？

一、Recap and Preview

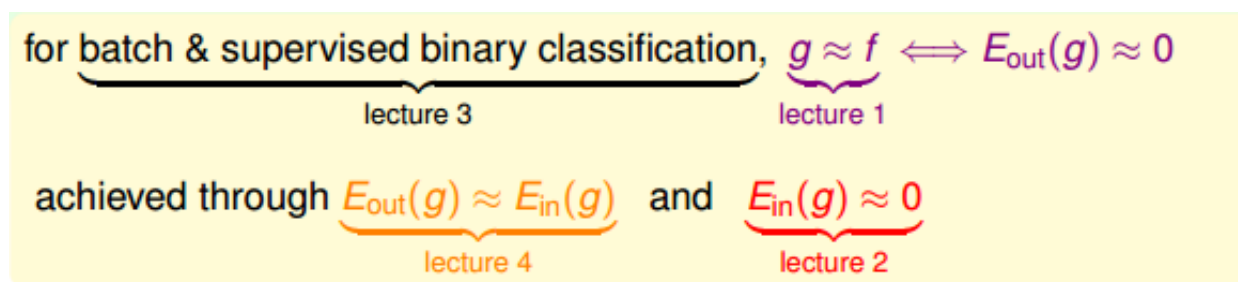
我们先来看一下基于统计学的机器学习流程图：



该流程图中，训练样本 \mathcal{D} 和最终测试 h 的样本都是来自同一个数据分布，这是机器能够学习的前提。另外，训练样本 \mathcal{D} 应该足够大，且hypothesis set的个数是有限的，这样根据霍夫丁不等式，才不会出现Bad Data，保证 $E_{in} \approx E_{out}$ ，即有很好的泛化能力。同时，通过训练，得到使 E_{in} 最小的 h ，作为模型最终的 g ， g 接近于目标函数。

这里，我们总结一下前四节课的主要内容：第一节课，我们介绍了机器学习的定义，目标是找出最好的 g ，使 $g \approx f$ ，保证 $E_{out}(g) \approx 0$ ；第二节课，我们介绍了如何让 $E_{in} \approx 0$ ，可以使用PLA、pocket等演算法来实现；第三节课，我们介绍了机器学习的分类，我们的训练样本是批量数据（batch），处理监督式（supervised）二元分类（binary classification）问题；第四节课，我们介绍了机器学习的可行性，通过统计学知识，把 $E_{in}(g)$ 与 $E_{out}(g)$ 联系起来，证明了在一些条件假设下，

$E_{in}(g) \approx E_{out}(g)$ 成立。



这四节课总结下来，我们把机器学习的主要目标分成两个核心的问题：

- $E_{in}(g) \approx E_{out}(g)$
- $E_{in}(g)$ 足够小

上节课介绍的机器学习可行的一个条件是hypothesis set的个数M是有限的，那M跟上面这两个核心问题有什么联系呢？

我们先来看一下，当M很小的时候，由上节课介绍的霍夫丁不等式，得到 $E_{in}(g) \approx E_{out}(g)$ ，即能保证第一个核心问题成立。但M很小时，演算法A可以选择的hypothesis有限，不一定能找到使 $E_{in}(g)$ 足够小的hypothesis，即不能保证第二个核心问题成立。当M很大的时候，同样由霍夫丁不等式， $E_{in}(g)$ 与 $E_{out}(g)$ 的差距可能比较大，第一个核心问题可能不成立。而M很大，使得演算法A的可以选择的hypothesis就很多，很有可能找到一个hypothesis，使 $E_{in}(g)$ 足够小，第二个核心问题可能成立。

- 1 can we make sure that $E_{out}(g)$ is close enough to $E_{in}(g)$?
- 2 can we make $E_{in}(g)$ small enough?

small M

- 1 Yes!,
 $\mathbb{P}[\mathbf{BAD}] \leq 2 \cdot M \cdot \exp(\dots)$
- 2 No!, too few choices

large M

- 1 No!,
 $\mathbb{P}[\mathbf{BAD}] \leq 2 \cdot M \cdot \exp(\dots)$
- 2 Yes!, many choices

从上面的分析来看，M的选择直接影响机器学习两个核心问题是否满足，M不能太大也不能太小。那么如果M无限大的时候，是否机器就不可以学习了呢？例如PLA算法中直线是无数条的，但是PLA能够很好地进行机器学习，这又是为什么呢？如果我们能将无限大的M限定在一个有限的 m_H 内，问题似乎就解决了。

二、Effective Number of Line


我们先看一下上节课推导的霍夫丁不等式：

$$P[|E_{in}(g) - E_{out}(g)| > \epsilon] \leq 2 \cdot M \cdot \exp(-2\epsilon^2 N)$$

其中，M表示hypothesis的个数。每个hypothesis下的BAD events B_m 级联的形式满足下列不等式：


$$P[B_1 \text{ or } B_2 \text{ or } \dots B_M] \leq P[B_1] + P[B_2] + \dots + P[B_M]$$

当 $M = \infty$ 时，上面不等式右边值将会很大，似乎说明BAD events很大， $E_{in}(g)$ 与 $E_{out}(g)$ 也并不接近。但是BAD events B_m 级联的形式实际上是扩大了上界，union bound过大。这种做法假设各个hypothesis之间没有交集，这是最坏的情况，可是实际上往往不是如此，很多情况下，都是有交集的，也就是说M实际上没那么大，如下图所示：



也就是说union bound被估计过高了 (over-estimating)。所以，我们的目的是找出不同BAD events之间的重叠部分，也就是将无数个hypothesis分成有限个类别。


如何将无数个hypothesis分成有限类呢？我们先来看这样一个例子，假如平面上用直线将点分开，也就跟PLA一样。如果平面上只有一个点 x_1 ，那么直线的种类有两种：一种将 x_1 划为+1，一种将 x_1 划为-1：




2 kinds: $h_1\text{-like}(x_1) = \circ$ or $h_2\text{-like}(x_1) = \times$

如果平面上有两个点 x_1 、 x_2 ，那么直线的种类共4种： x_1 、 x_2 都为+1， x_1 、 x_2 都


为-1, x_1 为+1且 x_2 为-1, x_1 为-1且 x_2 为+1 :




如果平面上有三个点 x_1 、 x_2 、 x_3 ，那么直线的种类共8种：



但是，在三个点的情况下，也会出现不能用一条直线划分的情况：



也就是说，对于平面上三个点，不能保证所有的8个类别都能被一条直线划分。那如果是四个点 x_1 、 x_2 、 x_3 、 x_4 ，我们发现，平面上找不到一条直线能将四个点组成的16个类别完全分开，最多只能分开其中的14类，即直线最多只有14种：



经过分析，我们得到平面上线的种类是有限的，1个点最多有2种线，2个点最多有4种线，3个点最多有8种线，4个点最多有14 ($< 2^4$) 种线等等。我们发现，有效直线的数量总是满足 $\leq 2^N$ ，其中，N是点的个数。所以，如果我们可以用 $\text{effective}(N)$ 代替 M，霍夫丁不等式可以写成：

$$P[|E_{in}(g) - E_{out}(g)| > \epsilon] \leq 2 \cdot \text{effective}(N) \cdot \exp(-2\epsilon^2 N)$$

已知 $\text{effective}(N) < 2^N$ ，如果能够保证 $\text{effective}(N) \ll 2^N$ ，即不等式右边接近于零，那么即使 M 无限大，直线的种类也很有限，机器学习也是可能的。

- must be $\leq 2^N$ (why?)
- finite 'grouping' of infinitely-many lines $\in \mathcal{H}$
- wish:

$$\begin{aligned} & \mathbb{P}[|E_{in}(g) - E_{out}(g)| > \epsilon] \\ & \leq 2 \cdot \text{effective}(N) \cdot \exp(-2\epsilon^2 N) \end{aligned}$$

lines in 2D

N	effective(N)
1	2
2	4
3	8
4	14 $< 2^N$

if ① $\text{effective}(N)$ can replace M and

② $\text{effective}(N) \ll 2^N$

learning possible with infinite lines :-)

三、Effective Number of Hypotheses

接下来先介绍一个新名词：二分类 (dichotomy)。dichotomy 就是将空间中的点 (例如二维平面) 用一条直线分成正类 (蓝色 o) 和负类 (红色 x)。令 H 是将平面上的点用直线分开的所有 hypothesis h 的集合，dichotomy H 与 hypotheses H 的关系是：

hypotheses H 是平面上所有直线的集合，个数可能是无限个，而 dichotomy H 是平面上能将点完全用直线分开的直线种类，它的上界是 2^N 。接下来，我们要做的就是尝试用 dichotomy 代替 M 。

- call

$$h(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N) = (h(\mathbf{x}_1), h(\mathbf{x}_2), \dots, h(\mathbf{x}_N)) \in \{\times, \circ\}^N$$

a **dichotomy**: hypothesis 'limited' to the eyes of $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$

- $\mathcal{H}(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N)$:

all dichotomies 'implemented' by \mathcal{H} on $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$

	hypotheses \mathcal{H}	dichotomies $\mathcal{H}(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N)$
e.g.	all lines in \mathbb{R}^2	$\{\circ\circ\circ\circ, \circ\circ\circ\times, \circ\circ\times\times, \dots\}$
size	possibly infinite	upper bounded by 2^N


再介绍一个新的名词：成长函数（growth function），记为 $m_H(H)$ 。成长函数的定义是：对于由 N 个点组成的不同集合中，某集合对应的 dichotomy 最大，那么这个 dichotomy 值就是 $m_H(H)$ ，它的上界是 2^N ：

$$m_{\mathcal{H}}(N) = \max_{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N \in \mathcal{X}} |\mathcal{H}(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N)|$$

成长函数其实就是我们之前讲的 effective lines 的数量最大值。根据成长函数的定义，二维平面上， $m_H(H)$ 随 N 的变化关系是：

lines in 2D	
N	$m_{\mathcal{H}}(N)$
1	2
2	4
3	$\max(\dots, 6, 8)$ $= 8$
4	$14 < 2^N$


接下来，我们讨论如何计算成长函数。先看一个简单情况，一维的 Positive Rays：



若有 N 个点，则整个区域可分为 $N+1$ 段，很容易得到其成长函数 $m_H(N) = N + 1$ 。

注意当 N 很大时， $(N + 1) \ll 2^N$ ，这是我们希望看到的。

另一种情况是一维的Positive Intervals：



它的成长函数可以由下面推导得出：


one dichotomy for each 'interval kind'

$$m_{\mathcal{H}}(N) = \underbrace{\binom{N+1}{2}}_{\text{interval ends in } N+1 \text{ spots}} + \underbrace{1}_{\text{all } \times}$$


$$= \frac{1}{2}N^2 + \frac{1}{2}N + 1$$

这种情况下， $m_H(N) = \frac{1}{2}N^2 + \frac{1}{2}N + 1 \ll 2^N$ ，在 N 很大的时候，仍然是满足的。

再来看这个例子，假设在二维空间里，如果hypothesis是凸多边形或类圆构成的封闭曲线，如下图所示，左边是convex的，右边不是convex的。那么，它的成长函数是多少呢？



当数据集 D 按照如下的凸分布时，我们很容易计算得到它的成长函数 $m_H = 2^N$ 。这种情况下， N 个点所有可能的分类情况都能够被hypotheses set覆盖，我们把这种情形称为shattered。也就是说，如果能够找到一个数据分布集，hypotheses set对 N 个输入所有的分类情况都做得得到，那么它的成长函数就是 2^N 。



四、Break Point

上一小节，我们介绍了四种不同的成长函数，分别是：

- | | |
|-----------------------|--|
| • positive rays: | $m_{\mathcal{H}}(N) = N + 1$ |
| • positive intervals: | $m_{\mathcal{H}}(N) = \frac{1}{2}N^2 + \frac{1}{2}N + 1$ |
| • convex sets: | $m_{\mathcal{H}}(N) = 2^N$ |
| • 2D perceptrons: | $m_{\mathcal{H}}(N) < 2^N$ in some cases |

其中，positive rays和positive intervals的成长函数都是polynomial的，如果用 $m_{\mathcal{H}}$ 代替 M 的话，这两种情况是比较好的。而convex sets的成长函数是exponential的，即等于 M ，并不能保证机器学习的可行性。那么，对于2D perceptrons，它的成长函数究竟是polynomial的还是exponential的呢？

对于2D perceptrons，我们之前分析了3个点，可以做出8种所有的dichotomy，而4个点，就无法做出所有16个点的dichotomy了。所以，我们就把4称为2D perceptrons的break point（5、6、7等都是break point）。令有 k 个点，如果 k 大于等于break point时，它的成长函数一定小于 2^k 。

根据break point的定义，我们知道满足 $m_{\mathcal{H}}(k) \neq 2^k$ 的 k 的最小值就是break point。对于我们之前介绍的四种成长函数，他们的break point分别是：

- positive rays: $m_{\mathcal{H}}(N) = N + 1 = O(N)$
break point at 2
- positive intervals: $m_{\mathcal{H}}(N) = \frac{1}{2}N^2 + \frac{1}{2}N + 1 = O(N^2)$
break point at 3
- convex sets: $m_{\mathcal{H}}(N) = 2^N$
no break point
- 2D perceptrons: $m_{\mathcal{H}}(N) < 2^N$ in some cases
break point at 4

通过观察，我们猜测成长函数可能与break point存在某种关系：对于convex sets，没有break point，它的成长函数是2的N次方；对于positive rays，break point k=2，它的成长函数是O(N)；对于positive intervals，break point k=3，它的成长函数是 $O(N^2)$ 。则根据这种推论，我们猜测2D perceptrons，它的成长函数 $m_H(N) = O(N^{k-1})$ 。如果成立，那么就可以用 m_H 代替M，就满足了机器能够学习的条件。关于上述猜测的证明，我们下节课再详细介绍。

五、总结

本节课，我们更深入地探讨了机器学习的可行性。我们把机器学习拆分为两个核心问题： $E_{in}(g) \approx E_{out}(g)$ 和 $E_{in}(g) \approx 0$ 。对于第一个问题，我们探讨了M个hypothesis到底可以划分为多少种，也就是成长函数 m_H 。并引入了break point的概念，给出了break point的计算方法。下节课，我们将详细论证对于2D perceptrons，它的成长函数与break point是否存在多项式的关系，如果是这样，那么机器学习就是可行的。

注明：

文章中所有的图片均来自台湾大学林轩田《机器学习基石》课程。